

## 1. 판다스 문제

### 1-1. Group Lens의 영화데이터

```
import numpy as np
```

```
import pandas as pd
```

```
arr1 = pd.read_csv('./data/ratings.csv')
```

```
arr2 = pd.read_csv('./data/movies.csv')
```

```
movie_name Rated = pd.merge(arr1, arr2, on='movieId', how='inner')
```

```
display(movie_name Rated.head())
```

```
# 1. 사용자가 평가한 모든 영화의 전체 평균 평점
```

```
mv1 = movie_name Rated
```

```
print('모든 영화의 평점 : ', mv1['rating'].mean())
```

```
# 2. 각 사용자별 평균 평점
```

```
mv2_dict = {
```

```
    '유저 ID' : [],
```

```
    '평균 평점' : []
```

```
}
```

```
mv2_user = []
```

```
mv2_rat = []
```

```
for (user,group) in movie_nameRated.groupby(['userId']):
```

```
    mv2_dict['유저 ID'].append(user)
```

```
    mv2_dict['평균 평점'].append(group['rating'].mean())
```

```
mv2 = pd.DataFrame(mv2_dict).set_index('유저 ID')
```

```
display(mv2)
```

-----

```
# 3. 각 영화별 평균 평점
```

```
mv3_dict = {
```

```
    '영화제목' : [],
```

```
    '평균 평점' : []
```

```
}
```

```
for (mvnm,group) in movie_nameRated.groupby(['title']):
```

```
#     print(mvnm)
```

```
#     print('=====')
```

```
#     print(group.head())
```

```
#     print('=====')
```

```
    mv3_dict['영화제목'].append(mvnm)
```

```
    mv3_dict['평균 평점'].append(group['rating'].mean())
```

```
mv3 = pd.DataFrame(mv3_dict).set_index('영화제목')
```

```
display(mv3)
```

-----

# 4. 평균 평점이 가장 높은 영화의 제목(동물이 있을 경우 모두 출력)

```
p4 = movie_nameRated['rating'].groupby(movie_nameRated['movieId']).mean()
```

```
high_rate = p4[p4 == p4.max()]
```

```
print(high_rate)
```

```
result = pd.merge(high_rate, arr2, left_index = True, right_on = 'movieId', how='inner')
```

```
display(result)
```

-----

# 5. Comedy영화 중 가장 평점이 낮은 영화의 제목

```
comedy_movie_id = arr2.loc[arr2['genres'].str.contains('Comedy')]['movieId']
```

```
comedy_mask = arr1['movieId'].isin(comedy_movie_id)
```

```
low_rating = arr1.loc[comedy_mask].groupby('movieId').mean()['rating'].min()
```

```
low_rating_mask = arr1.loc[comedy_mask].groupby('movieId').mean()['rating'] == low_rating
```

```
low_movie_id = arr1.loc[comedy_mask].groupby('movieId').mean().loc[low_rating_mask].index
```

```
low_movie_id = list(low_movie_id)
```

```
display(arr2.loc[arr2['movieId'].isin(low_movie_id)].sort_values(by='title'))
```

-----

```
from datetime import datetime
```

```
import time
```

```
start_stmp = '2015-01-01 0:0:1'
```

```
start_timestamp = time.mktime(datetime.strptime(start_stmp, '%Y-%m-%d %H:%M:%S').timetuple())
```

```
end_stmp = '2015-12-31 23:59:59'
```

```
end_timestamp = time.mktime(datetime.strptime(end_stmp, '%Y-%m-%d %H:%M:%S').timetuple())
```

```
date_mask = ((movie_nameRated['timestamp'].values >= start_timestamp) &  
(movie_nameRated['timestamp'].values <= end_timestamp))
```

```
result1 = movie_nameRated[date_mask]
```

```
result1.loc[result1['genres'].str.contains('Romance')]['rating'].mean()
```

-----

1-2. mpg data set문제

-----

```
import numpy as np
```

```
import pandas as pd
```

```
mpg_data = pd.read_csv('./data/mpg.csv')
```

```
display(mpg_data)
```

-----

# 1. displ(배기량)이 4 이하인 자동차와 5 이상인 자동차 중

# 어떤 자동차의 hwy(고속도로 연비)가 평균적으로 더 높은지 확인하세요.

```
mask_1 = mpg_data['displ'].values<=4
```

```
mask_2 = mpg_data['displ'].values>=5
```

```
if (mpg_data[mask_1]['hwy'].mean()) > (mpg_data[mask_2]['hwy'].mean()):
```

```
    print('displ이 4 이하인 자동차의 평균 hwy가 더 높다')
```

```
elif (mpg_data[mask_1]['hwy'].mean()) == (mpg_data[mask_2]['hwy'].mean()):
```

```
    print('평균 hwy가 같다')
```

```
else:
```

```
    print('displ이 5 이상인 자동차의 평균 hwy가 더 높다')
```

```
print(mpg_data[mask_1]['hwy'].mean())
```

```
print(mpg_data[mask_2]['hwy'].mean())
```

-----

# 2. 자동차 제조 회사에 따라 도시 연비가 다른지 알아보려고 한다.

# "audi"와 "toyota" 중 어느 manufacturer(제조회사)의 cty(도시 연비)가

# 평균적으로 더 높은지 확인하세요.

```
toyota = mpg_data['manufacturer'] == 'toyota'
```

```
audi = mpg_data['manufacturer'] == 'audi'
```

```
print(mpg_data[toyota]['cty'].mean())
```

```
print(mpg_data[audi]['cty'].mean())
```

```
if (mpg_data[toyota]['cty'].mean()) > (mpg_data[audi]['cty'].mean()):
```

```

    print('toyota 자동차의 평균 cty가 더 높다')

elif (mpg_data[toyota]['cty'].mean()) == (mpg_data[audi]['cty'].mean()):

    print('평균 cty가 같다')

else:

    print('audi 자동차의 평균 cty가 더 높다')

-----

# 3. "chevrolet", "ford", "honda" 자동차의 고속도로 연비 평균을 알아보려고 한다.

# 이 회사들의 데이터를 추출한 후 hwy(고속도로 연비) 평균을 구하세요.

chevrolet = mpg_data['manufacturer'] == 'chevrolet'

ford = mpg_data['manufacturer'] == 'ford'

honda= mpg_data['manufacturer'] == 'honda'

mask_3 = (mpg_data['manufacturer'] == 'chevrolet') | (mpg_data['manufacturer'] == 'ford') |
(mpg_data['manufacturer'] == 'honda')

print(' 3개 회사의 자동차의 고속도로 연비 평균 : ', mpg_data[mask_3]['hwy'].mean())

-----

# 4. "audi"에서 생산한 자동차 중에 어떤 자동차 모델의 hwy(고속도로 연비)가

# 높은지 알아보려고 한다. "audi"에서 생산한 자동차 중 hwy가 1~5위에 해당하는

# 자동차의 데이터를 출력하세요.

audi_data = mpg_data[audi]

display(audi_data)

```

```
# print(audi_data['hwy'].groupby(audi_data['model']).mean())

display(audi_data.sort_values(by = 'hwy',ascending=False).head())
```

-----

```
# 5. mpg 데이터는 연비를 나타내는 변수가 2개입니다.
# 두 변수를 각각 활용하는 대신 하나의 통합 연비 변수를 만들어 사용하려 합니다.
# 평균 연비 변수는 두 연비(고속도로와 도시)의 평균을 이용합니다.
# 회사별로 "suv" 자동차의 평균 연비를 구한후 내림차순으로 정렬한 후 1~5위까지 데이터를 출력하세요.
```

```
avg_data = (mpg_data['cty'] + mpg_data['hwy'])/2
```

```
mpg_data['avg'] = avg_data
```

```
suv_id = mpg_data.loc[mpg_data['class'].str.contains('suv')]

display(suv_id.head())
```

```
mpg_5 = suv_id['avg'].groupby(suv_id['manufacturer']).mean()

print(mpg_5.sort_values(ascending=False).head())
```

-----

```
# 6. mpg 데이터의 class는 "suv", "compact" 등 자동차의 특징에 따라
# 일곱 종류로 분류한 변수입니다. 어떤 차종의 도시 연비가 높은지 비교하려 합니다.
# class별 cty 평균을 구하고 cty 평균이 높은 순으로 정렬해 출력하세요.
```

```
mpg_6 = mpg_data['cty'].groupby(mpg_data['class']).mean()
```

```
print(mpg_6.sort_values(ascending=False))
```

-----

```
# 7. 어떤 회사 자동차의 hwy(고속도로 연비)가 가장 높은지 알아보려 합니다.
```

```
# hwy(고속도로 연비) 평균이 가장 높은 회사 세 곳을 출력하세요.
```

```
mpg_7 = mpg_data['hwy'].groupby(mpg_data['manufacturer']).mean()
```

```
rank_7 = mpg_7.sort_values(ascending=False)
```

```
rank_7.index[0]
```

```
for x in range(3):
```

```
    print([rank_7.index[x] , np.float16(rank_7.values[x]) ])
```

-----

```
# 8. 어떤 회사에서 "compact" 차종을 가장 많이 생산하는지 알아보려고 합니다.
```

```
# 각 회사별 "compact" 차종 수를 내림차순으로 정렬해 출력하세요.
```

```
compact_id = mpg_data.loc[mpg_data['class']=='compact']
```

```
display(compact_id.head())
```

```
mpg_8 = compact_id.groupby(mpg_data['manufacturer']).size()
```

```
print(mpg_8.sort_values(ascending=False))
```

-----

```
1-3. 한국복지패널데이터
```

-----

```
import pandas as pd
```



```

import numpy as np

import savReaderWriter

with savReaderWriter.SavReader('./data/Koweps_hpc10_2015_beta1.sav', ioUtf8 = True) as reader:

    df = pd.DataFrame(reader.all(), columns = [s for s in reader.header])

print(df.shape)      # # (16664, 957)

display(df.head())

display(df['h10_g3'].head()) # 성별

display(df['h10_g4'].head()) # 태어난 연도

-----

# 1. 성별에 따른 월급 차이

# 과거에 비해 여성의 사회 진출이 활발하지만 직장에서의

# 위상에서는 여전히 차별이 존재하고 있는것이 사실.

# 실제로 그러한지 월급의 차이를 이용하여 사실을 확인해보자

df = df.loc[df['p1002_8aq1'] != np.nan]

display(df.head())

print(df['p1002_8aq1'].groupby(df['h10_g3']).mean())

-----

# 2. 나이와 월급의 관계

# 몇 살 때 월급을 가장 많이 받을까? 또 그때의 월급은 얼마인가?

money = df.groupby(df['h10_g4']).mean().sort_values(by='p1002_8aq1',ascending=False)

```

```
age = 2020 - (money['p1002_8aq1'].index[0]) + 1  
print('{}살 때 약 {}만 원을 번다.'.format(int(age), int(money['p1002_8aq1'].values[0])))
```

-----  
# 3. 연령대에 따른 월급 차이

# 30세 미만을 초년(young), 1992 ~

# 30~59세 : 중년(middle), 1962~1991

# 60세 이상 : 노년(old) ~1961

# 위의 범주로 연령대에 따른 월급의 차이를 알아보자

```
young = df.loc[(df['h10_g4']>=1992)]
```

```
middle = df.loc[(df['h10_g4']<=1991)&(df['h10_g4']>=1962)]
```

```
old = df.loc[(df['h10_g4']<=1961)]
```

```
print('=====')
```

```
print('초년의 월급 : ',young['p1002_8aq1'].mean())
```

```
print('=====')
```

```
print('중년의 월급 : ',middle['p1002_8aq1'].mean())
```

```
print('=====')
```

```
print('노년의 월급 : ',old['p1002_8aq1'].mean())
```

```
print('=====')
```

-----  
# 4. 연령대 및 성별 월급 차이

# 성별 월급 차이는 연령대에 따라 다른 양상을 보일 수 있습니다.

# 성별 월급 차이가 연령대에 따라 다른지 분석해보자

# 기존에는 3그룹(초년,중년,노년)이었지만 이젠 6그룹으로

```
# 그룹핑을 해야 한다.(초년남성,초년여성,..)
```

```
young_man = young.loc[(young['h10_g3']==1)]
```

```
young_woman = young.loc[(young['h10_g3']==2)]
```

```
middle_man = middle.loc[(middle['h10_g3']==1)]
```

```
middle_woman = middle.loc[(middle['h10_g3']==2)]
```

```
old_man = old.loc[(old['h10_g3']==1)]
```

```
old_woman = old.loc[(old['h10_g3']==2)]
```

```
print('=====')
```

```
print('초년      남성의      월급      {}만원,      여성의      월급      {}만원  
' .format(np.float16(young_man['p1002_8aq1'].mean()),np.float16(young_woman['p1002_8aq1'].mean()  
()))
```

```
print('=====')
```

```
print('중년      남성의      월급      {}만원,      여성의      월급      {}만원  
' .format(np.float16(middle_man['p1002_8aq1'].mean()),np.float16(middle_woman['p1002_8aq1'].mea  
n()))
```

```
print('=====')
```

```
print('노년      남성의      월급      {}만원,      여성의      월급      {}만원  
' .format(np.float16(old_man['p1002_8aq1'].mean()),np.float16(old_woman['p1002_8aq1'].mean()))
```

```
print('=====')
```

-----

```
# 5. 직업별 월급 차이
```

```
# 어떤 직업이 월급을 가장 많이 받을까?
```

```
# 직업별 월급을 분석해 보자
```

```
# 직업코드는 제공된 Koweps_Codebook.xlsx를 이용하면
```

```
# 편하게 코드값을 이용 할 수 있습니다.
```

```
df1 = pd.read_excel("./data/Koweps_Codebook.xlsx", sheet_name='직종 코드')
```

```
job_money = df.groupby(df['h10_eco9'])
```

```
best_money = job_money['p1002_8aq1'].mean().sort_values(ascending=False)
```

```
display(best_money)
```

```
best_money_job = df1.loc[df1['code_job'] == best_money.index[0]]['job'].values
```

```
print('월급을 가장 많이 받는 직업군 : ',best_money_job )
```

```
-----
```

```
#####  
#####
```

```
# 6. 성별 직업 빈도
```

```
# 성별로 어떤 직업이 가장 많을까?
```

```
# display(job_money.loc[(job_money['h10_g3'] == 1)])
```

```
m_df = df.loc[(df['h10_g3'] == 1)]
```

```
w_df = df.loc[(df['h10_g3'] == 2)]
```

```
m_df_d = m_df['h10_eco9'].dropna()
```

```
display(m_df_d)
```

```
w_df_d = w_df['h10_eco9'].dropna()
```

```
display(w_df_d)
```

```
man_p6 = {}
```

```
woman_p6 = {}
```

```
for k in m_df_d:
```

```
    if k not in man_p6:
```

```
        man_p6[k] = 1
```

```
    elif k in man_p6:
```

```
        man_p6[k] += 1
```

```
s1 = sorted(man_p6.items(), reverse = True ,key = lambda x : x[1])
```

```
best_money_m = df1.loc[df1['code_job'] == s1[0][0]]['job'].values
```

```
print(s1)
```

```
for j in w_df_d:
```

```
    if j not in woman_p6:
```

```
        woman_p6[j] = 1
```

```
    elif j in woman_p6:
```

```
        woman_p6[j] += 1
```

```
s2 = sorted(woman_p6.items(), reverse = True ,key = lambda x : x[1])
```

```
best_money_w = df1.loc[df1['code_job'] == s2[0][0]]['job'].values
```

```
print(s2)
```

```
print(best_money_m)
```

```
print(best_money_w)
```

---

```
# 7. 종교 유무에 따른 이혼율
```

```
# 종교가 있는 사람들이 이혼을 덜 할까??
```

```
rel_Y = df.loc[(df['h10_g11'] == 1)]
```

```
rel_N = df.loc[(df['h10_g11'] == 2)]
```

```
#display(rel_Y.head())
```

```
#display(rel_N.head())
```

```
#print(rel_Y['h10_g10'] == 3)
```

```
#print(rel_N['h10_g10'] == 3)
```

```
# h10_g10 혼인상태,
```

```
YD = rel_Y.loc[rel_Y['h10_g10'] == 3]
```

```
ND = rel_N.loc[rel_N['h10_g10'] == 3]
```

```
print('종교가 있으며 이혼 : ', YD.shape[0])
```

```
print('종교가 없으며 이혼 : ', ND.shape[0])
```

---

```
# 8. 지역별 연령대 비율
```

```
# 노년층이 많은 지역은 어디일까?
```

```
#df['학점'].groupby(df['학과'])
```

```
#display(old)
```

```
old_region = old.groupby(old['h10_reg7']).size()
```

```
r = old_region.sort_values(ascending=False)
```

```
print('1. 서울, 2. 수도권(인천/경기), 3. 부산/경남/울산, 4.대구/경북, 5. 대전/충남, 6. 강원/충북, 7.광  
주/전남/전북/제주도')
```

```
print('{}번 지역이 노년층이 가장 많다'.format(r.index[0]))
```

-----

## 2. titanic data

```
import numpy as np

import tensorflow as tf

import pandas as pd

from scipy import stats

import matplotlib.pyplot as plt

from sklearn.preprocessing import MinMaxScaler

tf.reset_default_graph()

train = pd.read_csv('./data/train.csv')

# df2 = pd.read_csv('./data/test.csv')

# display(df2)

# PassengerId : 승객일련번호 _ 필요 X

# Survived : 생존여부 _ label

# Pclass : 객실 등급

# 상관계수를 구해보고 연관성을 파악해서 살린다.

# Name : 이름 _ 필요 X

# Age : 나이 _ 필요 O
```



```
# 결측치 포함되어 있다.
```

```
# 1. 모든 사람의 평균
```

```
# 2. 이름에 포함된 MR, MRS, MISS를 고려해 평균나이 사용
```

```
# 유아(0) 청소년(1) 성인(2) 노인(3)
```

```
# Sex : male, Female => 0,1로 변경
```

```
# SibSp, Parch : column을 합쳐 num_of_family
```

```
# Ticket : 삭제
```

```
# Fare : 요금 _ 고민을 해 봐야 한다.
```

```
# Cabin : 객실번호 X
```

```
# Embarked : 승선위치 S,C,Q => 숫자로 바꿔서 처리
```

```
#####
```

```
# 필요없는 column 삭제
```

```
train.drop(['PassengerId','Name','Ticket','Fare', 'Cabin'],axis=1,inplace=True)
```

```
# 성별 처리
```

```
sex_mapping = {'male':0, 'female':1}
```

```
train['Sex'] = train['Sex'].map(sex_mapping)
```

# 가족 구성원

```
train['Family'] = train['SibSp']+train['Parch']
```

```
train.drop(['SibSp', 'Parch'],axis=1,inplace=True)
```

# 결측치

```
# train.isnull().sum()
```

```
# Survived      0
```

```
# Pclass        0
```

```
# Sex           0
```

```
# Age          177
```

```
# Embarked      2
```

```
# Family        0
```

# Embarked 결측치

```
train['Embarked'] = train['Embarked'].fillna('Q')
```

# Embarked 변환

```
Embarked_mapping = {'S':0, 'C':1, 'Q':2}
```

```
train['Embarked'] = train['Embarked'].map(Embarked_mapping)
```

# Age 결측치

```
train['Age'] = train['Age'].fillna(train['Age'].mean())
```

# Age에 대해 Binning 처리 (Numerical value -> Categorical value)

```
train.loc[train['Age']<8,'Age']=0
```

```
train.loc[(train['Age']>=8) & (train['Age'] < 20) ,'Age']=1
```

```
train.loc[(train['Age']>=20) & (train['Age'] < 65) , 'Age']=2
```

```
train.loc[train['Age']>=65,'Age']=3
```

```
display(train.head())
```

```
# 데이터 준비 완료
```

```
# Tensorflow를 이용해서 학습 진행 및 Accuracy를 구현
```

```
#train = train.drop('Survived',axis=1, inplace = False).values.reshape(-1,5)
```

```
brd = int(train.shape[0]*0.7)
```

```
train_data = train.iloc[0:brd]
```

```
test_data = train.iloc[brd:]
```

```
x_data_train = train_data.drop('Survived',axis=1, inplace = False).values.reshape(-1,5)
```

```
t_data_train = train_data['Survived'].values.reshape(-1,1)
```

```
x_data_test = test_data.drop('Survived',axis=1, inplace = False).values.reshape(-1,5)
```

```
t_data_test = test_data['Survived'].values.reshape(-1,1)
```

```
# Tensorflow
```

```
X = tf.placeholder(shape=[None,5], dtype= tf.float32)
```

```
T = tf.placeholder(shape=[None,1], dtype= tf.float32)
```

```
W = tf.Variable(tf.random.normal([5,1]),name='Weight')
```

```
b = tf.Variable(tf.random.normal([1]),name='bias')
```

```
# # Hypothesis
```

```
# logit = tf.matmul(X,W)+b
```

```
# H = tf.sigmoid(logit)
```

```
drop_rate = tf.placeholder(dtype = tf.float32)
```

```
# Weight & bias
```

```
W2 = tf.get_variable('weight2', shape=[5,5],
```

```
                    initializer = tf.contrib.layers.variance_scaling_initializer())
```

```
b2 = tf.Variable(tf.random.normal([5]), name='bias2')
```

```
_layer2 = tf.nn.relu(tf.matmul(X,W2) + b2)
```

```
layer2 = tf.nn.dropout(_layer2, rate = drop_rate)
```

```
W3 = tf.get_variable('weight3', shape = [5,5],
```

```
                    initializer = tf.contrib.layers.variance_scaling_initializer())
```

```
b3 = tf.Variable(tf.random.normal([5]), name='bias3')
```

```
_layer3 = tf.nn.relu(tf.matmul(layer2,W3) + b3)
```

```
layer3 = tf.nn.dropout(_layer3, rate = drop_rate)
```

[illegible]

```

if step % 30000 == 0:

    print('W : {}, b : {}, loss : {}'.format(W_val,b_val,loss_val))


predict = tf.cast(H >= 0.5, dtype=tf.float32) # True = 1, False = 0

correct = tf.equal(predict,T)

accuracy = tf.reduce_mean(tf.cast(correct, dtype=tf.float32))


accuracy_val = sess.run(accuracy, feed_dict={X:x_data_test,T:t_data_test, drop_rate : 0})

print('Accuracy : {}'.format(accuracy_val))


test = pd.read_csv('./data/test.csv')


PassengerId = test['PassengerId']

test.drop(['PassengerId','Name','Ticket','Fare', 'Cabin'],axis=1,inplace=True)


# 성별 처리

sex_mapping = {'male':0, 'female':1}

test['Sex'] = test['Sex'].map(sex_mapping)


# 가족 구성원

test['Family'] = test['SibSp']+test['Parch']

test.drop(['SibSp', 'Parch'],axis=1,inplace=True)


# Embarked 결측치

```

```
test['Embarked'] = test['Embarked'].fillna('Q')
```

```
# Embarked 변환
```

```
Embarked_mapping = {'S':0, 'C':1, 'Q':2}
```

```
test['Embarked'] = test['Embarked'].map(Embarked_mapping)
```

```
# Age 결측치
```

```
test.loc[test['Age'].isnull(), 'Age'] = np.nanmedian(test['Age'].values)
```

```
# Age에 대해 Binning 처리 (Numerical value -> Categorical value)
```

```
test.loc[test['Age'] < 8, 'Age'] = 0
```

```
test.loc[(test['Age'] >= 8) & (test['Age'] < 20), 'Age'] = 1
```

```
test.loc[(test['Age'] >= 20) & (test['Age'] < 65), 'Age'] = 2
```

```
test.loc[test['Age'] >= 65, 'Age'] = 3
```

```
test_x = test.values.reshape(-1, 5)
```

```
predict = tf.cast(H >= 0.5, dtype=tf.float32) # True = 1, False = 0
```

```
results = sess.run(predict, feed_dict={X:test_x, drop_rate : 0})
```

```
# results = model.predict(test)
```

```
# select the index with the maximum probability
```

```
#results = pd.Series(results.ravel(),name="Survived")

#submission = pd.concat([pd.Series(range(892,1310),name = "PassengerId"),results],axis = 1)

submission = pd.DataFrame(

    {

        'PassengerId': PassengerId,

        'Survived': results.ravel().astype(int)

    }

)



submission.to_csv("submission2.csv",index=False)
```

Your most recent submission

Name	Submitted	Wait time	Execution time	Score
submission2.csv	2 minutes ago	0 seconds	0 seconds	0.77272


Complete

[Jump to your position on the leaderboard](#)



11...	Ricky Wilkes		0.77272	1	26m
11...	dpruuY		0.77272	3	2m

Your Best Entry

Your submission scored 0.77272



Tweet this!

11...	Rachel Bright		0.77033	1	2mo
11...	Thaddeus Dai		0.77033	11	2mo



### 3. mnist data

```
import numpy as np
```

```
import pandas as pd
```

```
import tensorflow as tf
```

```
from scipy import stats
```

```
from sklearn.model_selection import train_test_split
```

```
from sklearn.preprocessing import MinMaxScaler
```

```
from sklearn.model_selection import KFold
```

```
train = pd.read_csv('./data/digit-recognizer/train.csv')
```

```
test = pd.read_csv('./data/digit-recognizer/test.csv')
```

```
display(train.head())
```

```
display(test.head())
```

```
# 1. 결측치 확인
```

```
train.isnull().sum()
```

```
# zscore = 1.8
```

```
# for t in train.columns:
```

```
#     df.loc[np.abs(stats.zscore(df[t])) >= zscore,:]
```

```
train_x = train.drop('label',axis=1, inplace = False)
```

```
train_t = train['label']
```

```
x_data_train, x_data_test, t_data_train, t_data_test = W
```

```
train_test_split(train_x, train_t, test_size=0.3, random_state=0)
```

```
scaler = MinMaxScaler()
```

```
scaler.fit(x_data_train)
```

```
x_data_train_norm = scaler.transform(x_data_train)
```

```
x_data_test_norm = scaler.transform(x_data_test)
```

```
sess = tf.Session()
```

```
t_data_train_onehot = sess.run(tf.one_hot(t_data_train, depth=10))
```

```
t_data_test_onehot = sess.run(tf.one_hot(t_data_test, depth=10))
```

```
del t_data_train
```

```
del t_data_test
```

```
# Training data set 준비완료
```

```
# Tensorflow Graph 그리기
```

```
# Placeholder
```

```
X = tf.placeholder(shape=[None, 784], dtype=tf.float32)
```

```
T = tf.placeholder(shape=[None,10],dtype=tf.float32)
```

```
# Weight & bias
```

```
W = tf.Variable(tf.random.normal([784,10]), name = 'weight')
```

```
b = tf.Variable(tf.random.normal([10]), name = 'bias')
```

```
# Hypothesis(Model)
```

```
logit = tf.matmul(X,W)+b
```

```
H = tf.nn.softmax(logit)
```

```
# loss function
```

```
loss = tf.reduce_mean(tf.nn.softmax_cross_entropy_with_logits_v2(logits=logit,  
                                                                    labels=T))
```

```
# train
```

```
train = tf.train.GradientDescentOptimizer(learning_rate=0.1).minimize(loss)
```

```
# 반복학습하는 함수
```

```
num_of_epoch = 1000
```

```
batch_size = 100 # 한번에 학습할 x_data, t_data의 행의 수 16000개중 100개 씩 학습
```

```
def run_train(sess, train_x, train_t):
```

```
    print('### 학습 시작 ###')
```

```
    sess.run(tf.global_variables_initializer()) # session 초기화
```

```
total_batch = int(train_x.shape[0] / batch_size)
```

```
for step in range(num_of_epoch):
```

```
    for i in range(total_batch): # 0 ~ 139
```

```
        batch_x = train_x[i*batch_size:(i+1)*batch_size] # train_x[0:100]
```

```
        batch_t = train_t[i*batch_size:(i+1)*batch_size] # train_t[0:100]
```

```
        _, loss_val = sess.run([train,loss], feed_dict={X:batch_x ,
```

```
                                T:batch_t})
```

```
    if step % 100 == 0:
```

```
        print('Loss : {}'.format(loss_val))
```

```
print('### 학습 종료 ###')
```

```
# Accuracy (정확도 측정)      #      0      1      2
```

```
predict = tf.argmax(H,1)      # [[0.5  0.4  0.1]]  입력 값에 대한 예측
```

```
correct = tf.equal(predict, tf.argmax(T,1))
```

```
accuracy = tf.reduce_mean(tf.cast(correct,dtype=tf.float32))
```

```
# # training data로 validation
```

```
# run_train(sess,x_data_train_norm,t_data_train_onehot)
```

```
# # Accuracy 측정 (training data로 validation)
```

```
# result = sess.run(accuracy, feed_dict={X:x_data_train_norm ,
#                                         T:t_data_train_onehot})
```

```
# print('training data로 validation {}'.format(result))
```

```
# # 비추천
```

```
# # Cross Validation 추천
```

```
# Cross Validation
```

```
cv= 5
```

```
results = []
```

```
kf = KFold(n_splits=cv, shuffle=True)
```

```
for training_idx, validation_idx in kf.split(x_data_train_norm):
```

```
    # training_idx : index 값을 알아온다
```

```
    train_x = x_data_train_norm[training_idx]
```

```
    train_t = t_data_train_onehot[training_idx]
```

```
    valid_x = x_data_train_norm[validation_idx]
```

```
    valid_t = t_data_train_onehot[validation_idx]
```

```
    run_train(sess,train_x,train_t)
```

```
    results.append(sess.run(accuracy,
                            feed_dict={X:valid_x,
                                        T:valid_t}))
```

```

print('Cross Validation 결과 : {}'.format(results))

print('Cross Validation 최종 결과 : {}'.format(np.mean(results)))

result = sess.run(accuracy, feed_dict={X:x_data_test_norm ,
                                       T:t_data_test_onehot})

print('최종 정확도 {}'.format(result))

# predict results
my_state_scaled = scaler.transform(test)
results = sess.run(H, feed_dict={X:my_state_scaled})

# results = model.predict(test)





# select the index with the maximum probability
results = np.argmax(results,axis = 1)


results = pd.Series(results,name="Label")

submission = pd.concat([pd.Series(range(1,28001),name = "ImageId"),results],axis = 1)

submission.to_csv("result.csv",index=False)


```

2187	hyeonjinlim		0.90739	1	26m
2188	ChrisCC	 </> Logistic Regression...	0.90689	4	1mo
2189	Kipyo Kim		0.90617	2	1mo
2190	dpruuY		0.90614	1	~10s

Your First Entry   
Welcome to the leaderboard!

Digit Recognizer

Learn computer vision fundamentals with the famous MNIST data

 Kaggle 2,461 teams Ongoing

Overview

Data

Notebooks

Discussion

Leaderboard

Rules

Team

My Submissions

Submit Predictions

1 submissions for <a href="#">dpruuY</a>		Sort by	Most recent
<div>All   Successful   Selected</div>			
Submission and Description		Public Score	
<a href="#">result.csv</a> 8 days ago by <a href="#">dpruuY</a> practice		0.90614	
No more submissions to show			